# 词汇表和倒排记录表

# The term vocabulary and postings lists

*节选自王斌老师《现代信息检索》课程的课件

# 本讲的内容

- 索引构建过程(特别是预处理）
- 如何对索引文档进行处理来得到词典
  - 理解文档(document)的概念
  - 词条化(Tokenization)，理解词条(token)的概念
  - 词项生成，理解词项(term)的概念
- 倒排记录表
  - 更快的合并算法: 跳表法(skip list)
  - 短语查询的处理及带位置信息的倒排索引

# 提纲

1. 文档
2. 词项
   - 通常做法+非英语处理
   - 英语
3. 跳表指针
4. 短语查询

# 回顾倒排索引构建

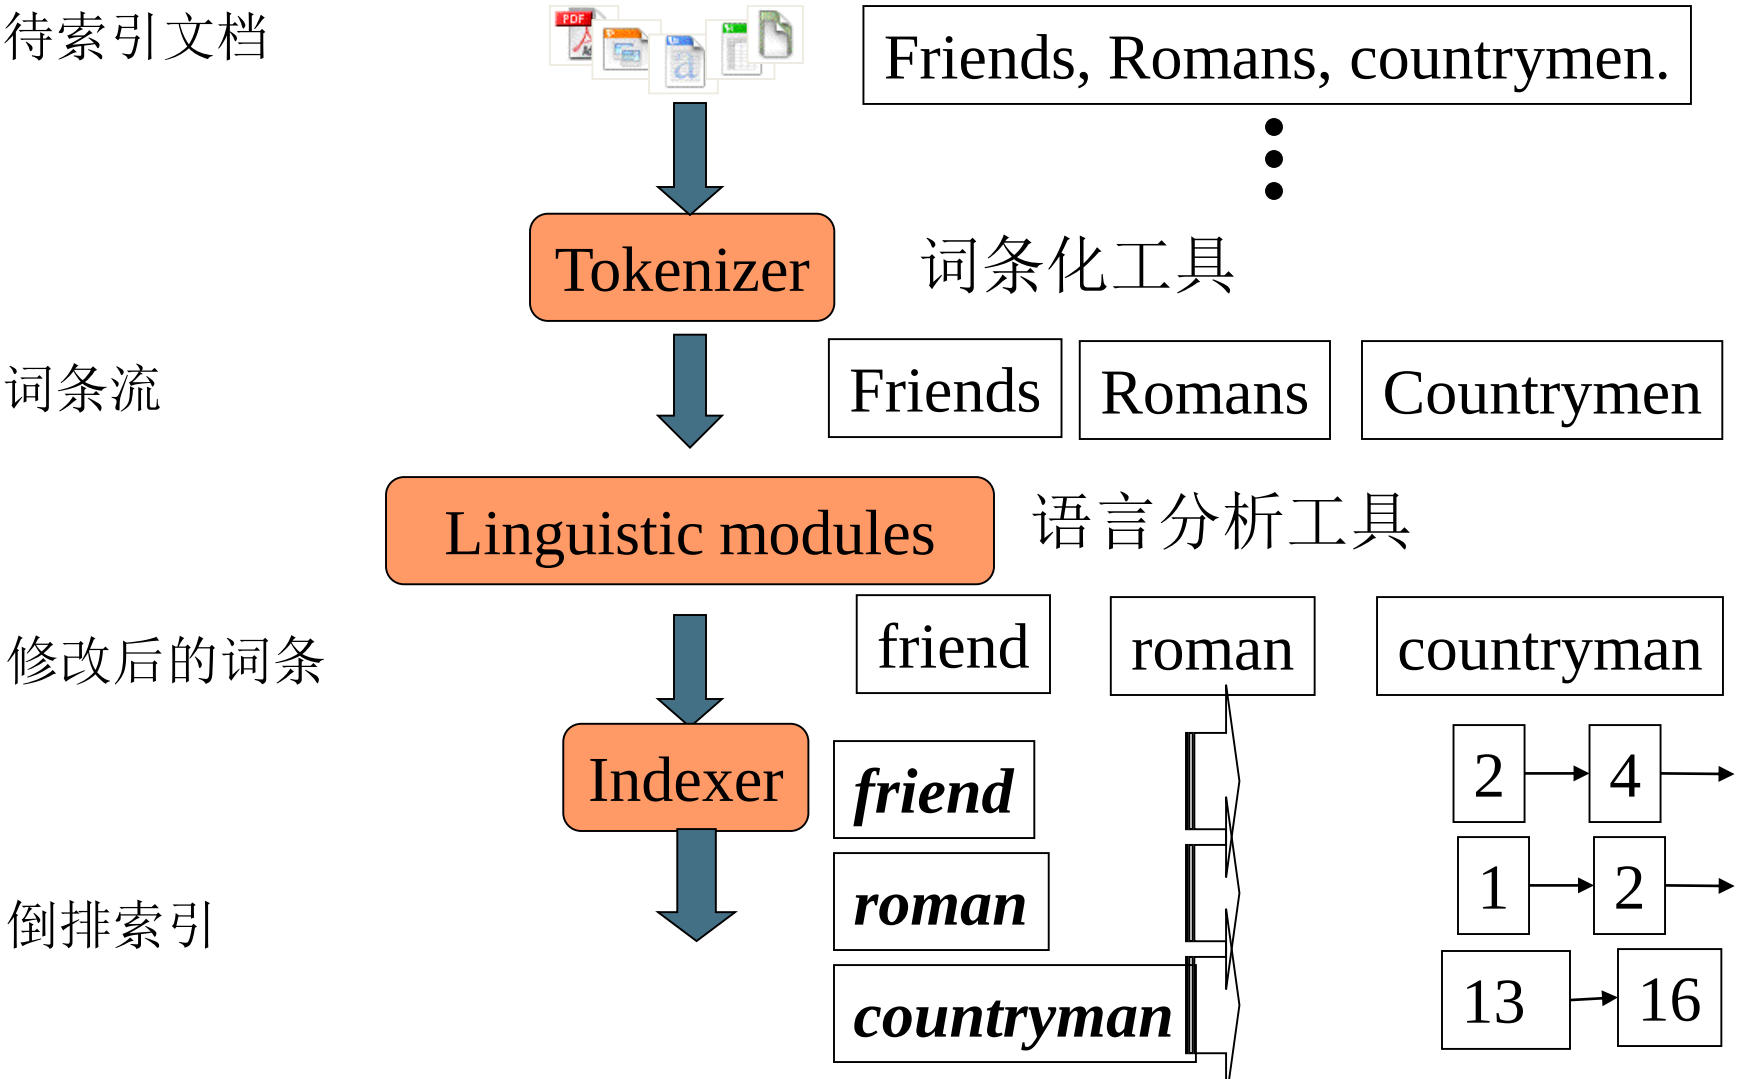
待索引文档
Friends, Romans, countrymen.
Tokenizer
词条化工具
词条流
Friends
Romans
Countrymen
Linguistic modules
语言分析工具
修改后的词条
friend
roman
countryman
Indexer
倒排索引
friend
roman
countryman
2
4
1
2
13
16

# 文档分析

- 文档格式处理
  - pdf/word/excel/html?
- 文档语言识别
- 文档编码识别

文档语言识别和编码识别理论上都可以看成分类问题，基于后面章节的分类方法可以处理。但是实际中，常常采用启发式方法……

# 多格式/语言并存

- 待索引文档集可能同时包含多种语言的文档
  - 在同一索引中词汇表中包含来自多个语言的词项
- 有时文档或者其部件中包含多种语言/格式
  - 法语邮件中带一个德语的pdf格式附件
- 如何确定索引的单位？
  - 文件为单位？
  - 邮件为单位？
  - 如果邮件带有5个附件，怎么办？
  - 一组文件？ (比如采用html格式写的某个PPT文档)

# 提纲

1. 文档
2. 词项
   - 通常做法+非英语处理
   - 英语
3. 跳表指针
4. 短语查询

词条和词项

# TOKENS AND TERMS

# 词条化(Tokenization)

- 输入: “Friends, Romans and Countrymen”
- 输出: 词条(Token)
  - Friends
  - Romans
  - Countrymen
- 词条 就是一个字符串实例
- 词条在经过进一步处理之后将放入倒排索引中的词典中
  - 后面会讲
- 词条化中的问题-词条如何界定?

# 词条化

- 一系列问题:
  - Finland’s capital →
  - Finland? Finlands? Finland’s?
  - Hewlett-Packard → 看成Hewlett 和 Packard 两个词条?
    - state-of-the-art:
    - co-education
    - lowercase, lower-case, lower case ?
  - San Francisco: 到底是一个还是两个词条？
    - 如何判断是一个词条？

# 词条化中数字的处理

- 3/20/91 Mar. 12, 1991 20/3/91
- 55 B.C.
- B-52
- PGP 密钥：324a3df234cb23e
- (800) 234-2333
  - 通常中间有空格
  - 早期的IR系统可能不索引数字
    - 但是数字却常常很有用：比如在Web上查找错误代码
    - (一种处理方法是采用n-gram: 见第三讲)
  - 元数据是分开还是一起索引
    - 创建日期、格式等等

# 语言问题：法语和德语

- 法语
  - L‘ensemble → 到底是一个还是两个词条?
    - L ? L’ ? Le ?
    - 但是常常希望 l’ensemble 能和un ensemble匹配
      - 至少在2003年以前，Google没有这样处理
        - 国际化问题!

- 德语中复合名词连写
  - Lebensversicherungsgesellschaftsangestellter
  - ‘life insurance company employee’
  - 德语检索系统往往要使用一个复合词拆分的模块，而且该模块对检索结果的提高有很大帮助(可以提高15%)

# 语言问题：中文和日文

- 中文和日文词之间没有间隔:
  - 莎拉波娃现在居住在美国东南部的佛罗里达。
  - 分词结果无法保证百分百正确，“和尚”
- 日文中可以同时使用多种类型的字母表
  - 日期/数字可以采用不同的格式

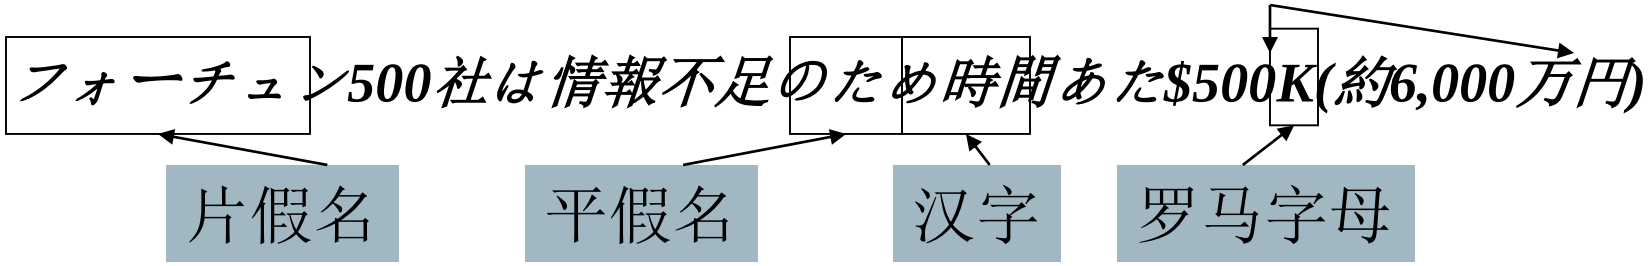


而终端用户可能完全用平假名方式输入查询！

# 中文分词(Chinese Word Segmentation)

- 对于中文，分词的作用实际上是要找出一个个的索引单位
- 例子：李明天天都准时上班
- 索引单位
  - 字：李 明 天 天 都 准 时 上 班
    - 索引量太大，查全率百分百，但是查准率低，比如查“明天”这句话也会出来
  - 词：李明 天天 都 准时 上班
    - 索引量大大降低，查准率较高，查全率不是百分百，而且还会受分词错误的影响，比如上面可能会切分成：李 明天 天都 准时 上班，还有： 他和服务人员照相
  - 字词混合方式/k-gram/多k-gram混合
  - 一般原则，没把握的情况下细粒度优先

# 中文分词和检索

- 以下是当前某些研究的结论或猜测，仅供参考
- 并非分词精度高一定检索精度高
  - 评价标准不同
  - 分词规范问题： 鸡蛋、鸭蛋、鹌鹑蛋……
  - 目标不同
- 检索中的分词：
  - 查询和文档切分采用一致的分词系统
  - 速度快
  - 倾向细粒度，保证召回率
  - 多粒度并存
- 搜索引擎中的分词方法
  - 猜想：大词典+统计+启发式规则

# 语言问题：阿拉伯文

- 阿拉伯文 (或希伯来文) 通常从右到左书写，但是某些部分(如数字)是从左到右书写
- 词之间是分开的，但是单词中的字母形式会构成复杂的连接方式

اس تق تل ال جز ائر ف ي س نة 1962 ب ع د 132 ع ام ا من ا ل ح ت ل ال ف ر ن س ي.

- ← → ← → ← 开始
- ‘Algeria achieved its independence in 1962 after 132 years of French occupation.’
- 在Unicode编码方式下，表面的表示方式很复杂，但是存储上倒是十分直接

# 停用词

- 根据停用词表(stop list), 将那些最常见的词从词典中去掉。比如直观上可以去掉：
  - 一般不包含语义信息的词: the, a, and, to, be
  - 汉语中的“的”、“得”、“地”等等。
  - 这些词都是高频词: 前30个词就占了 ~30% 的倒排记录表空间

- 现代信息检索系统中倾向于不去掉停用词:
  - 在保留停用词的情况下，采用良好的压缩技术(第五章)后，停用词所占用的空间可以大大压缩，最终它们在整个倒排记录表中所占的空间比例很小
  - 采用良好的查询优化技术(第七章)基本不会增加查询处理的开销
  - 所谓的停用词并不一定没用，比如：短语查询: “King of Denmark”、歌曲名或者台词等等: “Let it be”, “To be or not to be”、“关系型” 查询 “flights to London”

# 词条归一化(Normalization)成词项

- 将文档和查询中的词归一化成同一形式：
  - U.S.A. 和 USA
- 归一化的结果就是词项，而词项就是我们最终要索引的对象
- 可以采用隐式规则的方法来表示多个词条可以归一成同一词项，比如
  - 剔除句点
    - U.S.A., USA　USA
  - 剔除连接符
    - anti-discriminatory, antidiscriminatory　antidiscriminatory

# 归一化中的语言问题

- 重音符: 如法语中 résumé vs. resume.
- 日耳曼语系中的元音变化: 如德语中的 Tuebingen vs. Tübingen
  - 应该是一致的
- 最重要的准则:
  - 用户在输入查询时遇到这些词如何输入?

- 即使在有重音符号的语言中，用户也往往不输入这些符号
  - 常常归一化成不带重音符号的形式
    - Tuebingen, Tübingen, Tubingen ⎣ Tubingen

# 归一化中的语言问题

- 时间格式
  - 7月30日 vs. 7/30
  - 日语中用假名或者汉字表示日期

- 词条化和归一化都可能与语言相关，因此必须要做语言识别

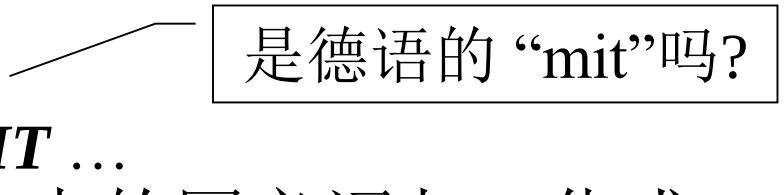


***Morgen will ich in MIT*** …

- 另外，谨记要将文档和查询中的同义词归一化成同一形式

# 提纲

1. 上一讲回顾
2. 文档
3. 词项
   - 通常做法+非英语处理
   - 英语
4. 跳表指针
5. 短语查询

# 大小写问题


- 可以将所有字母转换成小写形式
  - 例外: 句中的大写单词？
    - e.g., General Motors（GM，通用公司）
    - Fed (美联储)vs. fed(饲养)
    - SAIL (印度钢铁管理局) vs. sail(航行)
  - 通常情况下将所有字母转成小写是一种很合适的方式，因为用户倾向于用小写方式输入

- Google的例子:
  - 查询 C.A.T.
  - 排名第一的结果是“cat”而不是 Caterpillar Inc.

# 归一化成词项

- 除了前面互换方式(即能够归一化成同一词项的词条之间完全平等，可以互换)之外，另一种方式是非对称扩展 (asymmetric expansion)
- 一个非对称扩展更适合的的例子
  - 输入: window　　搜索: window, windows
  - 输入: windows　　搜索: Windows, windows, window
  - 输入: Windows　　搜索: Windows
  - 为什么反过来不行？
- 这种方法可能更强大，但是效率低一些

# 同义词词典(Thesauri)及soundex方法

- 同义词和同音/同形异义词的处理
  - E.g., 手动建立词典，记录这些词对
    - car = automobile　　color = colour
  - 利用上述词典进行索引
    - 当文档包含 automobile时, 利用car-automobile进行索引
  - 或者对查询进行扩展
    - 当查询包含 automobile时，同时也查car
- 拼写错误的处理(Clinton→Klinten)
  - 一种解决方法是soundex方法，基于发音建立词之间的关系

# 词形归并(Lemmatization)

- 将单词的屈折变体形式还原为原形
- 例子：
  - am, are, is → be
  - car, cars, car's, cars' → car
  - the boy's cars are different colors → the boy car be different color
- 词性归并意味中将单词的变形形式“适当”还原成一般词典中的单词形式
  - found → find? found?

# 词干还原（Stemming）

- 将词项归约(reduce)成其词干(stem)，然后再索引
- “词干还原” 意味着词缀的截除
  - 与语言相关
  - 比如，将 automate(s), automatic, automation都还原成 automat

***for example compressed and compression are both accepted as equivalent to compress***.

for exampl compress and compress ar both accept as equival to compress

# Porter算法

- 英语词干还原中最常用的算法
  - 结果表明该方法不差于其他的词干还原方法
- 一些规定+ 5 步骤的归约过程
  - 这些步骤有先后顺序
  - 每一步都包含一系列命令
- 一些规定，比如: 选择可应用规则组中包含最长词缀的规则
  - SSES →SS caresses →caress
  - S → cats →cat

# Porter中的典型规则

- sses → ss
- ies → i
- ational → ate
- tional → tion

- 规则适用条件的表达
  - (m>1) EMENT →
    - replacement → replac
    - cement → cement

# Martin Porter

- (应该是)英国人，(应该是)剑桥大学
- 2000年度 Tony Kent Strix award得主
  - 信息检索领域另一个著名的奖项

- Porter’s stemmer，有很多语言的版本
- Snowball 工具，支持多种语言的stemming(法语、德语、葡萄牙语、西班牙语挪威语等等)

# 其他词干还原工具(stemmer)

- Lovins: http://www.comp.lancs.ac.uk/computing/research/stemming/general/lovins.htm
- 单遍扫描，最长词缀剔除 (大概 250条规则)
- 全部基于词形分析 – 对于检索来说最多只能提供一定的帮助(at most modest benefits for retrieval)
- 词干还原及其它归一化工作对检索的帮助
  - 英语： 结果要一分为二，对某些查询来说提高了召回率，但是对另外一些查询来说降低了正确率
  - 比如, operative (dentistry) ➔ oper
  - 对西班牙语、德语、芬兰语等语言非常有用
  - 其中对于芬兰语有30% 的性能提高!

# 语言特性

- 上述很多转换处理具体实现时
  - 都与语言本身有关，并且
  - 常常和具体应用有关
- 上述过程可以插件方式植入索引过程

- 存在很多开源和商业插件可用

# 提纲

1. 文档
2. 词项
   - 通常做法+非英语处理
   - 英语
3. 跳表指针
4. 短语查询

快速倒排表合并—跳表法

# FASTER POSTINGS MERGES: SKIP POINTERS/SKIP LISTS

# 基本合并算法的回顾

- 两个指针，同步扫描，线性时间

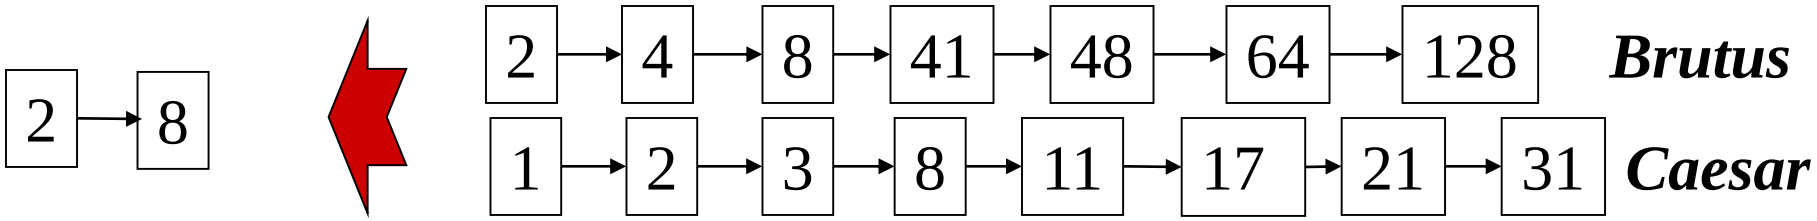


两个表长度为*m*和*n*的话，上述合并时间复杂度为 O(*m*+*n*)

能否做得更好？答案是可以(如果索引不常变化的话)

# 索引构建时为倒排记录表增加跳表指针

- 为什么可以加快速度?
  - 可以跳过那些不可能的检索结果

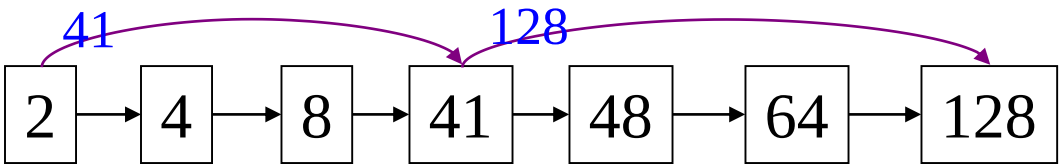


- 如何做?也就是在什么地方加跳表指针?

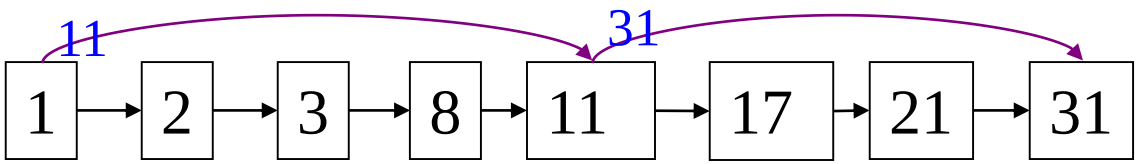

# 基于跳表指针的查询处理

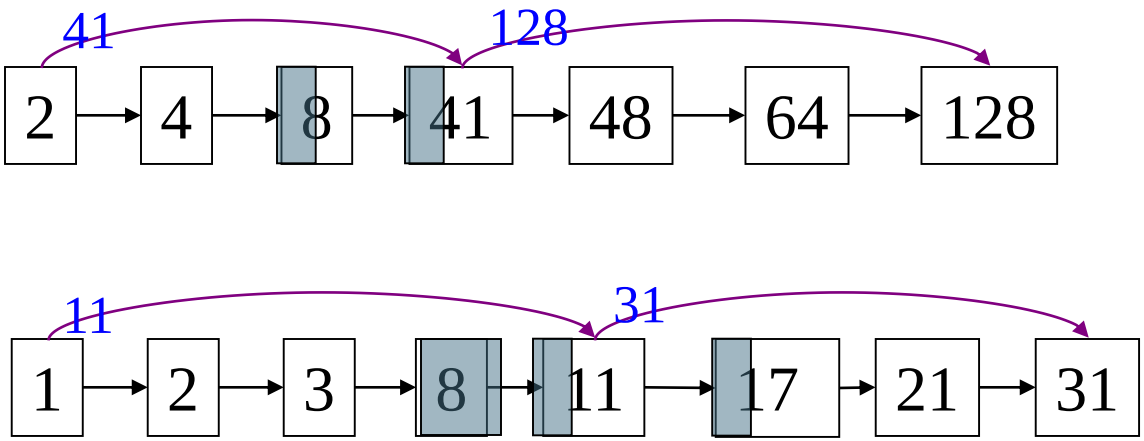


假定匹配到上下的指针都指向8，接下来两个指针都向下移动一位。

比较**41和11，11小**

此时看11上面的跳表指针，指向31，31仍然比41小，于是下指针可以直接跳过中间的11、17、21、31

# 跳表指针的位置

- 指针数目过多过少都不合适，要有一个均衡性:
  - 指针越多 $\rightarrow$ 跳步越短 $\Rightarrow$ 更容易跳转，但是需要更多的与跳表指针指向记录的比较
  - 指针越少 $\rightarrow$ 比较次数越少，但是跳步越长 $\Rightarrow$ 成功跳转的次数少

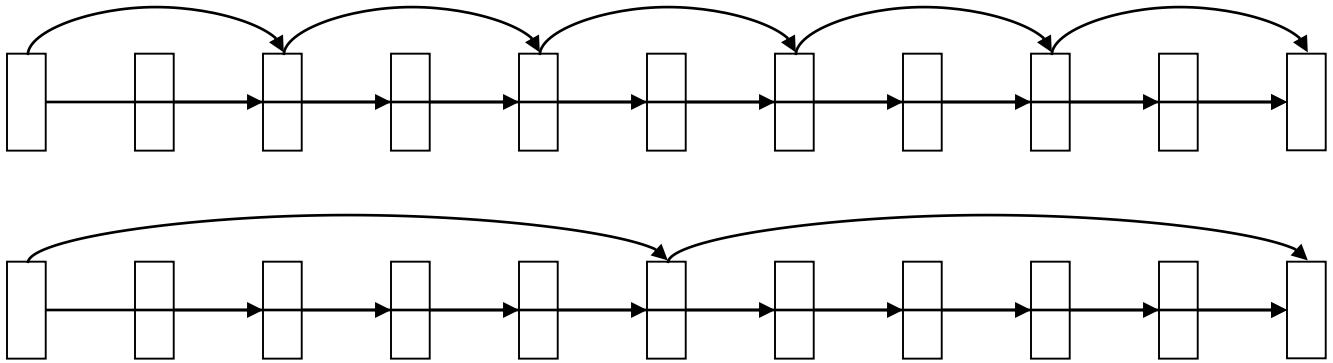

# 跳表指针的位置

- 简单的启发式策略：对于长度为L的倒排记录表，每$\sqrt{L}$处放一个跳表指针，即均匀放置。均匀放置方法忽略了查询词项的分布情况
- 如果索引相对静态，均匀方式方法是一种很简便的方法，但是如果索引经常更新造成L经常变化，均匀方式方式就很不方便
- 跳表方式在过去肯定是有用的，但是对于现代的硬件设备而言，如果合并的倒排记录表不能全部放入内存的话，上述方式不一定有用 (Bahle et al. 2002)
  - 更大的倒排记录表(含跳表)的 I/O开销可能远远超过内存中合并带来的好处

# 提纲

1. 文档
2. 词项
   - 通常做法+非英语处理
   - 英语
3. 跳表指针
4. 短语查询

短语查询及位置索引

# PHRASE QUERIES AND POSITIONAL INDEXES

# 短语查询

- 输入查询作为一个短语整体，比如 “stanford university” “中国科学院”
- 因此，句子 “I went to university at Stanford” 就不应该是答案 （“我去了中国 农业 科学院”）
  - 有证据表明，用户很容易理解短语查询的概念，这也是很多搜索引擎 “高级搜索”中比较成功的一个功能。
  - 但是很多查询是隐式短语查询， information retrieval textbook → [information retrieval] textbook
- 这种情况下，倒排索引仅仅采用如下方式是不够的
- term + docIDs

# 第一种做法: 双词(Biword)索引

- 每两个连续的词组成词对(作为短语)来索引
- 比如文本片段 “Friends, Romans, Countrymen” 会产生两个词对
  - friends romans
  - romans countrymen
- 索引构建时，将每个词对看成一个词项放到词典中
- 这样的话，两个词组成的短语查询就能直接处理

# 更长的短语查询处理

- 例子： stanford university palo alto，处理方法：将其拆分成基于双词的布尔查询式:
- stanford university AND university palo AND palo alto

- 如果不检查文档，无法确认满足上述表达式的文档是否真正满足上述短语查询。也就是说满足上述布尔表达式只是满足短语查询的充分条件。

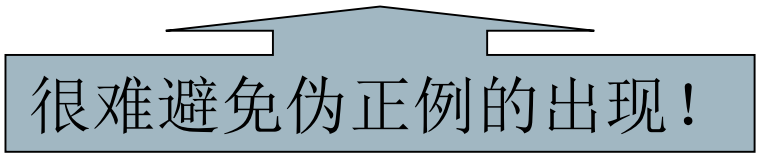

# 扩展的双词（Extended Biword）

- 对待索引文档进行词性标注
- 将词项进行组块，每个组块包含名词 (N) 和冠词/介词 (X)
- 称具有NX*N形式的词项序列为扩展双词(extended biword)
  - 将这样扩展词对作为词项放入词典中
- 例子：catcher in the rye (书名： 麦田守望者)
  - N X X N
- 查询处理：将查询也分析成 N和X序列
  - 将查询切分成扩展双词
  - 在索引中查找: catcher rye

# 关于双词索引

- 会出现伪正例子
- 由于词典中词项数目剧增，导致索引空间也激增
  - 如果3词索引，那么更是空间巨大，无法忍受

- 双词索引方法并不是一个标准的做法 (即倒排索引中一般不会全部采用双词索引方法)，但是可以和其他方法混合使用

# 第二种解决方法: 带位置信息索引 (Positional indexes)

- 在倒排记录表中，对每个term在每篇文档中的每个位置(偏移或者单词序号)进行存储:

  - <term, 出现term的文档篇数;
  - doc1: 位置1, 位置2 … ;
  - doc2: 位置1, 位置2 … ;
  - 等等>

# 位置索引的例子

- 对于输入的短语查询，需要在文档的层次上进行迭代(不同位置上)合并
- 不仅仅简单合并，还要考虑位置匹配

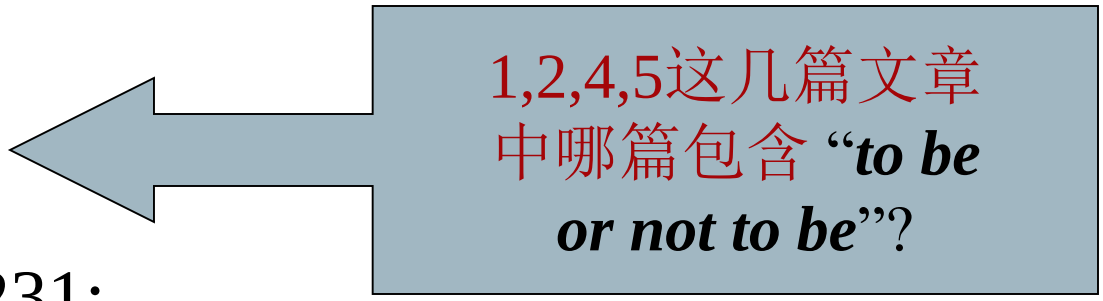


<***be***: 993427;
*1*: 7, 18, 33, 72, 86, 231;
*2*: 3, 149;
*4*: 17, 191, 291, 430, 434;
*5*: 363, 367, …>

# 短语查询的处理

- 短语查询：“to be or not to be”
- 对每个词项，抽出其对应的倒排记录表: to, be, or, not.
- 合并<docID:位置 >表，考虑 “to be or not to be”.
  - to:
    - 2:1,17,74,222,551; 4:8,16,190,429,433; 7:13,23,191; ...
  - be:
    - 1:17,19; 4:17,191,291,430,434; 5:14,19,101; ...
- 邻近搜索中的搜索策略与此类似，不同的是此时考虑前后位置之间的距离不大于某个值

# 邻近式查询(Proximity query)

- LIMIT! /3 STATUTE /3 FEDERAL /2 TORT
  - /k 表示 “在 k 个词之内”
- 很明显，位置索引可以处理邻近式查询，而双词索引却不能

# 位置索引的大小

- 位置索引增加了位置信息，因此空间较大，但是可以采用索引压缩技术进行处理(参见第五讲)
- 当然，相对于没有位置信息的索引，位置索引的存储空间明显大于无位置信息的索引
- 另外，位置索引目前是实际检索系统的标配，这是因为实际中需要处理短语(显式和隐式)和邻近式查询

# 位置索引的大小

- 词项在每篇文档中的每次出现都需要一个存储单元
- 因此索引的大小依赖于文档的平均长度
  - 平均Web页面的长度 <1000 个词项
  - 美国证监会文件(SEC filings), 书籍, 甚至一些史诗 … 和容易就超过 100,000 个词项
- 假定某个词项的出现频率是0.1%

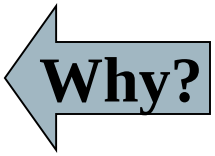


| 文档大小 | 倒排记录表的数目 | 位置索引存储单元 |
|---|---|---|
| 1000 | 1 | 1 |
| 100,000 | 1 | 100 |

# 一些经验规律

- 位置索引的大小大概是无位置信息索引的2-4倍
- 位置索引大概是原始文本容量的35-50%
- 提醒：上述经验规律适用于英语及类英语的语言

# 混合索引

- 上述两种索引方式可以混合使用
  - 对某些特定的短语 (如“Michael Jackson”, “Britney Spears”)，如果采用位置索引的方式那么效率不高
    - 还有“The Who”（英国一著名摇滚乐队），采用位置索引，效率更低
- Williams et al. (2004)对一种混合的索引机制进行了评估
  - 采用混合机制，那么对于典型的Web查询(比例)来说，相对于只使用位置索引而言，仅需要其¼ 的时间
  - 相对于只使用位置索引，空间开销只增加了26%

# 本讲小结

- 索引构建过程(特别是预处理）
- 如何对索引文档进行处理来得到词典
  - 理解文档(document)的概念
  - 词条化(Tokenization)，理解词条(token)的概念
  - 词项生成，理解词项(term)的概念
- 倒排记录表
  - 更快的合并算法: 跳表法(skip list)
  - 短语查询的处理及带位置信息的倒排索引